

On commence par entraîner un modèle:

- On prend des milliards de textes (par exemple tout le WEB !!)
- Les textes sont découpés en petits morceaux quelconques (*au hasard*): les syllabes, les ponctuations, les chiffres, etc.
- On associe à chaque morceau un code (un *token*)
- On fabrique une gigantesque table de tous les *tokens* ordonnés
- On calcule la probabilité d'occurrence croisée de tous les *tokens*

Ceci donne le **modèle**.

- On ne cherche jamais à comprendre les mots ni les morceaux de mots !!!

LLM

chatGPT, Claude, Copilote, Le Chat, ...

Le contexte est l'ensemble de la base d'apprentissage et du prompt

Ensuite on *encode* (de la même façon) ce que tu veux demander au LLM:

Ceci constitue le **prompt**

Le LLM calcule alors :

- Quel est le prochain token le plus probable dans ce contexte de ce prompt ?
- Il choisit celui qui a la meilleure probabilité.
- Puis il ajoute ce résultat au prompt et recommence... encore et encore...
- Jusqu'à former une phrase complète.

C'est tout !!

- Il n'y a jamais aucune compréhension des textes considérés, uniquement une association logique et probabiliste